מאגרי נתונים לסיווג תתי-גרפים:
שבעת המאגרים שנבחרו

11 באוקטובר 2026

מה אנחנו מחפשים

אנחנו מסווגים ישות, שאנחנו קוראים לה *צבע*, לפי תת-הגרף שלה בתוך גרף גדול אחד. בנתוני ההריון שלנו צומת הוא ביקור אחד, תת-גרף הוא כל הביקורים של מטופלת אחת, והתווית אומרת אם למטופלת היה התוצא. יש 61,046 ביקורים, 6,590 מטופלות, ו-11% מהן חיוביות. הקשתות מחברות ביקורים עם טקסט דומה (20 שכנים לכל ביקור).

מאגר מתאים אם יש בו ארבעה דברים. כל צומת שייך לתת-גרף אחד בדיוק, ובכל תת-גרף יש צמתים רבים. יש תווית אחת לכל תת-גרף, רצוי בינארית. הקשתות נבנות מטקסט או מווקטורים של הצמתים, או ניתנות על ידי המקור. ואי אפשר לנחש את התווית מגודל תת-הגרף בלבד.

מתוך 14 המועמדים בגרסה הראשונה של הדוח נבחרו שבעה: JODIE Reddit, Synthea 1k, Synthea 5k, Deezer Europe, CaLiGraph, Amazon, ו-Gene Ontology עם STRING. הגרסה הזו מתארת כל אחד מהם בפירוט. שלושה כבר בנויים; ארבעת האחרים לא.

במבט אחד

מאגר	צומת	תת-גרף (צבע אחד)	התווית של תת-הגרף	מצב
הריון (שלנו)	ביקור	הביקורים של מטופלת	היה התוצא	קיים
JODIE Reddit	פוסט	הפוסטים של משתמש	המשתמש נחסם	נבנה
Synthea 1k / 5k	ביקור	הביקורים של מטופל	למטופל יש סוכרת	נבנה
Deezer Europe	משתמש	קבוצת משתמשים (לבחירה)	רוב ממגדר אחד או לא	הורד
CaLiGraph	ישות	הישויות של מחלקה אחת	תחת מחלקת-אב או לא	עוד לא
Amazon	מוצר	המוצרים של קטגוריה אחת	ספרים או לא	עוד לא
GO + STRING	חלבון	החלבונים של מונח GO אחד	תחת מונח-אב או לא	עוד לא

טבלה 1: איך כל מאגר מתחלק לתתי-גרפים ומה התווית של כל תת-גרף. בארבעת האחרונים הקיבוץ והתווית הם ההצעה שלנו.

מקום בדיסק

מאגר	הורדה	בדיסק, פרוס	מקור המספר
JODIE Reddit	2.3 GB	2.3 GB	נמדד, כבר במחשב הזה
Synthea 1k	188 MB תוכנה של	226 MB	נמדד, כבר במחשב הזה
Synthea 5k	(אותה תוכנה)	1.1 GB	נמדד, כבר במחשב הזה
Deezer Europe	2.6 MB	7.5 MB	נמדד
CaLiGraph	1.4 GB (3.8 GB לכל הקבצים)	בערך 10–15 GB	ההורדה נמדדה, השאר הערכה
Amazon	221 MB	בערך 1 GB	ההורדה נמדדה, השאר הערכה
GO + STRING	בערך 200 MB	בערך 1 GB	ההורדה נמדדה, השאר הערכה
סך הכול	4.3 GB	בערך 16–21 GB	

טבלה 2: המקום שדרוש לקבצים הגולמיים. גודלי ההורדה נלקחו מהשרתים ב-11 באוקטובר 2026. הגודל הפרוס של הקבצים שעוד לא הורדו הוא הערכה. ההורדה החדשה היא בערך 1.8 GB אם לא סופרים שוב את JODIE ו-Synthea, שכבר נמצאים כאן.

רק CaLiGraph גדול. הקבצים שלו הם טקסט דחוס שגדל בערך פי עשרה כשפורסים אותו. אפשר גם לקרוא אותם בלי לפרוס, וכך הוא נשאר 1.4 GB.

גרפים בנויים דורשים מקום נוסף. הגרף המעובד של JODIE Reddit תופס 649 MB, ושל Synthea 130 MB (1k) ו-632 MB (5k). גרף מעובד גדל עם מספר הצמתים, ולכן CaLiGraph, עם מיליוני ישויות, ידרוש הרבה GB אם לא נשאיר רק חלק ממנו.

שלושת המאגרים הבנויים

המספרים לקוחים מהבנייה שלנו.

	תתי-גרפים	חיוביים	גודל ממוצע	חציון	הקטן–הגדול	גודל, חיובי / שלילי
הריון (שלנו)	6,590	11.4%	9.3	5	2–221	8.3 / 9.4
JODIE Reddit	10,000	3.7%	67.2	44	29–4,690	61.1 / 67.5
Synthea 1k	1,160	14.5%	58.0	36	1–810	**166.1** / 39.8
Synthea 5k	5,678	14.6%	57.4	36	1–866	**164.8** / 39.0

טבלה 3: גודל ואיזון התוויות של תתי-הגרפים. גודל הוא מספר הצמתים בתת-גרף. העמודה האחרונה היא הגודל הממוצע של תתי-גרפים חיוביים ושל שליליים.

	חלקים לתת-גרף (ממוצע)	קשתות בתוך תת-גרף (חלק מכל הקשתות)	שכנים עם אותה תווית	
			נצפה	באקראי
הריון (שלנו)	8.8 מתוך 9.3	0.4%	83.0%	81.7%
JODIE Reddit	45.9 מתוך 67.2	10.5%	93.7%	93.6%
Synthea 1k	47.7 מתוך 58.0	5.8%	79.4%	51.5%
Synthea 5k	52.5 מתוך 57.4	2.1%	79.9%	51.3%

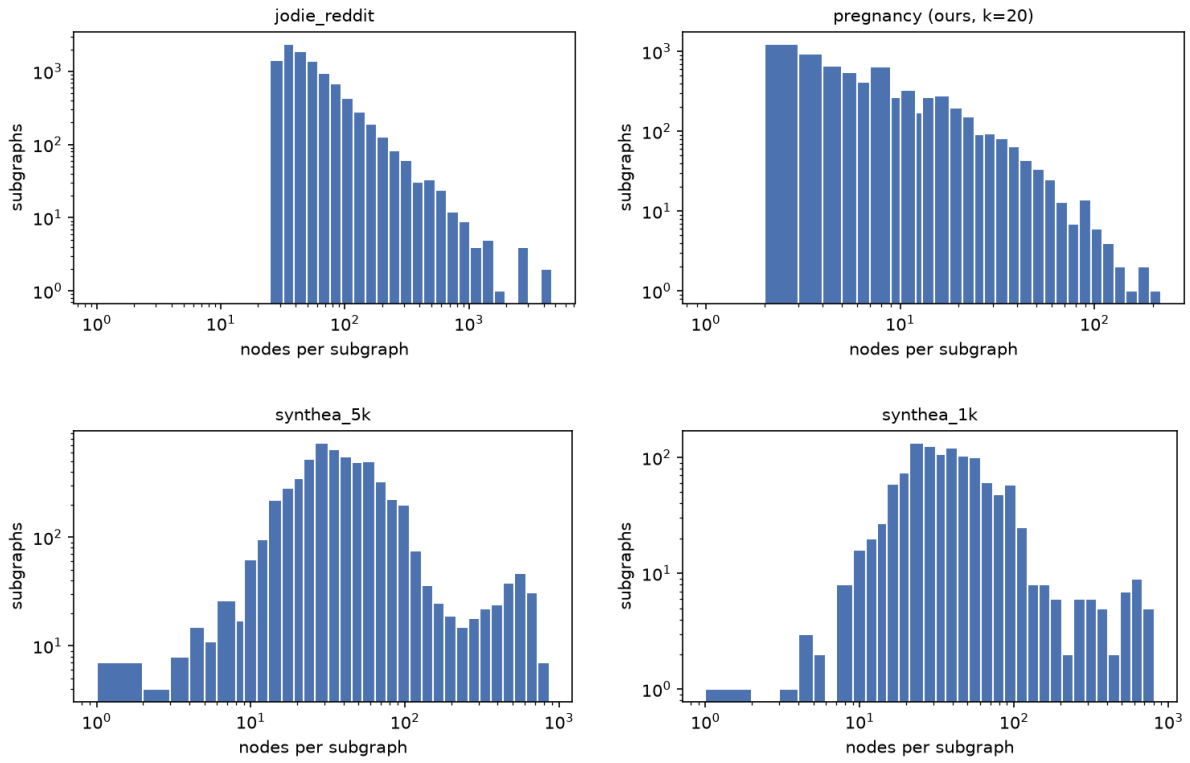
טבלה 4: איך תתי-הגרפים יושבים בגרף. *חלקים* הוא מספר החלקים הקשירים של תת-גרף כשמשאירים רק את הקשתות שלו (מתוך מספר הצמתים בו). *שכנים עם אותה תווית* מסתכל על קשתות בין שני תתי-גרפים שונים ושואל כמה פעמים לשניהם אותה תווית; *באקראי* הוא מה שהיינו רואים אם הקשתות האלה היו מונחות באקראי.

תתי-הגרפים שלנו קטנים בהרבה. למטופלת בהריון יש בממוצע 9 ביקורים. למשתמשים ולמטופלים ב-JODIE וב-Synthea יש בערך 60.

ב-Synthea הגודל מסגיר את התוויות. למטופלים חיוביים יש בערך פי ארבעה ביקורים (165 לעומת 39). ב-JODIE Reddit ובנתונים שלנו לשתי התוויות יש בערך אותו גודל.

תתי-הגרפים לא קשירים מבפנים. מטופלת עם 9.3 ביקורים מתפרקת ל-8.8 חלקים נפרדים. JODIE ו-Synthea קשירים קצת יותר, אבל עדיין רובם בחלקים.

רק ב-Synthea יש אות תווית בקשתות. ב-JODIE Reddit ובנתונים שלנו, תתי-גרפים שכנים חולקים תווית לא יותר מאשר במקרה. ב-Synthea הם חולקים אותה ב-80% מהפעמים לעומת 51% במקרה, ושוב ייתכן שזה בא מהגודל.



איור 1: מספר תתי-הגרפים בכל גודל, בצירים לוגריתמיים. ל-Synthea יש גבעה שנייה של מטופלים גדולים מאוד, בין 200 ל-900 ביקורים.

כל מאגר בפירוט

JODIE Reddit

מהמאמר של JODIE (Kumar, Zhang and Leskovec, KDD 2019). הוא מתעד חודש אחד של פוסטים של 10,000 המשתמשים הפעילים ביותר ב-Reddit, ב-984 ה-subreddits (פורומים לפי נושא) הפעילים ביותר.

מקור	snap.stanford.edu/jodie, קובץ אחד, `reddit.csv`, 2.3 GB. כבר נמצא ב-`data/raw/jodie_reddit`.
צומת	פוסט אחד. יש 672,447 פוסטים. כל שורה נותנת את המשתמש, ה-subreddit, הזמן ודגל חסימה.
וקטור צומת	172 מספרים שנוצרו מטקסט הפוסט בעזרת LIWC, כלי שסופר מילים לפי קטגוריה (למשל מילים עצובות או מילים על משפחה). הטקסט עצמו לא כלול, ולכן אי אפשר להטמיע אותו בדרך שלנו.
קשתות	לא ניתנות. אנחנו מחברים כל פוסט ל-20 הפוסטים הדומים לו ביותר לפי הווקטורים האלה, ומקבלים 10.5 מיליון קשתות.
תת-גרף	כל הפוסטים של משתמש אחד. לכל משתמש יש לפחות 29 פוסטים.
תווית	1 אם המשתמש נחסם ב-subreddit בשלב כלשהו, אחרת 0. רק 366 משתמשים (3.7%) חיוביים.
לא בשימוש	ה-subreddit והזמן של כל פוסט נמצאים בקובץ אבל לא בגרף שלנו.
בעיות	התווית נדירה, ובווקטורי LIWC יש מעט אות תווית: שכנים חולקים תווית לא יותר מאשר במקרה.

Synthea 1k ו-5k

Synthea היא תוכנה שממציאה רשומות רפואיות מציאותיות (קוד פתוח, של MITRE). לא מורידים דבר מלבד התוכנה; הרשומות נוצרות אצלנו.

מקור	github.com/synthetichealth/synthea, קובץ Java אחד של 188 MB. הרשומות נוצרות עם seed 42 עבור 1,000 ו-5,000 אנשים חיים. אנשים שמתים בדרך נשמרים גם הם, ולכן מתקבלים 1,160 ו-5,678 מטופלים.
קבצים	שבע טבלאות בכל הרצה: מטופלים, ביקורים, מצבים רפואיים, תרופות, פרוצדורות, בדיקות מעבדה וחיסונים. טבלת הבדיקות היא הגדולה ביותר (145 MB מתוך 226 MB ב-1k).
צומת	ביקור אחד: 67,331 ב-1k ו-325,760 ב-5k.
טקסט צומת	נבנה מהביקור: הסוג והסיבה שלו, ואחריהם האבחנות, הפרוצדורות, התרופות, החיסונים והבדיקות. כל אזכור של סוכרת ושל התרופות שלה מוסר. הטקסט מוטמע באותו מודל משפטים קטן כמו קודם (MiniLM).
קשתות	כל ביקור מחובר ל-20 הביקורים הדומים לו ביותר לפי הטקסט.
תת-גרף	כל הביקורים של מטופל אחד.
תווית	1 אם למטופל יש מצב כלשהו של סוכרת (לא כולל טרום-סוכרת), אחרת 0. בערך 15% חיוביים.
בעיות	למטופלים חיוביים יש פי ארבעה ביקורים, ולכן הגודל לבדו מנבא את התווית. רשומות סינתטיות גם סדירות יותר מרשומות אמיתיות. קיימת גם הרצה של 20k (4.5 GB), אבל היא לא נבחרה.

Deezer Europe

רשת חברתית של משתמשי שירות המוזיקה Deezer, שנאספה במרץ 2020 עבור המאמר FEATHER (Rozemberczki and Sarkar, 2020). הורדנו אותה כדי לבדוק את הקבצים.

מקור	SNAP, קובץ zip אחד של 2.6 MB עם שלושה קבצים: קשתות (1.0 MB), מאפיינים (6.2 MB) ותוויות (0.2 MB).

צומת	משתמש אחד. יש 28,281 משתמשים ממדינות באירופה.
וקטור צומת	רשימת האמנים שהמשתמש אהב, 34 בממוצע מתוך 31,241 אמנים. האמנים נתונים רק כמספרים, בלי שמות, ולכן אין טקסט.
קשתות	ניתנות: 92,752 מעקבים הדדיים. זה בערך 6.6 שכנים למשתמש, לעומת 32 בגרף שלנו. אפשר גם לחבר משתמשים שאוהבים אותם אמנים.
תווית צומת	המגדר של המשתמש, שהכותבים ניחשו לפי שם המשתמש. ל-44% מהמשתמשים יש תווית 1; הקבצים לא אומרים איזה מגדר זה.
תת-גרף	**לא נקבע.** הגרסה הראשונה הציעה את המשתמשים של מדינה אחת, אבל בקבצים אין מדינה. קבוצה צריכה לבוא מהגרף עצמו, למשל אשכולות של משתמשים שעוקבים זה אחרי זה או שאוהבים אותם אמנים.
תווית	1 אם לרוב המשתמשים בקבוצה יש תווית 1, אחרת 0.
בעיות	התווית של תת-הגרף נוצרת ממיצוע של תוויות צמתים, ולכן היא טובה רק כמו ניחוש המגדר לפי השם. כמה קבוצות נקבל, ובאיזה גודל, תלוי באשכול.

CaLiGraph

גרף ידע שנבנה מקטגוריות ומדפי רשימה של ויקיפדיה על גבי האונטולוגיה של DBpedia, באוניברסיטת מנהיים (Heist and Paulheim). יש בו יותר ממיליון מחלקות ומיליוני ישויות רבים (אנשים, מקומות, יצירות וכן הלאה).

מקור	Zenodo, גרסה 3.1.1 מיוני 2023, רישיון CC BY 4.0. אתר הפרויקט, שלא ענה ב-10 באוקטובר, ענה שוב ב-11 באוקטובר.
קבצים	13 קבצים דחוסים בפורמט N-Triples, פורמט טקסט עם עובדה אחת בכל שורה, 3.8 GB בסך הכול. אנחנו צריכים ארבעה מהם, 1.4 GB: האונטולוגיה, שמחזיקה את עץ המחלקות (32 MB); המחלקה של כל ישות (525 MB); השם של כל ישות (485 MB); והקשרים בין ישויות (345 MB).
צומת	ישות אחת.
טקסט צומת	רק שם הישות. טקסט ארוך יותר, כמו התקציר מוויקיפדיה, לא נמצא בקבצים האלה ויגיע מ-DBpedia.
קשתות	ניתנות: קשרים בין ישויות, למשל אדם והעיר שבה נולד. אפשר גם לחבר ישויות עם שמות או טקסט דומים.
תת-גרף	הישויות של מחלקה אחת. לישות יש מחלקות רבות, ולכן נשאיר את הספציפית ביותר.
תווית	1 אם המחלקה נמצאת תחת מחלקת-אב שנבחרה (למשל Person), אחרת 0.
צפוי	בערך 10 ישויות למחלקה בממוצע, קרוב ל-9 הביקורים שלנו למטופלת.
בעיות	גדול מדי לשימוש כולו, ולכן צריך לחתוך חלק. שמות של מחלקות וישויות אומרים לא פעם את המחלקה במפורש ("American novelists"), מה שעלול להפוך את התווית לקלה.

Amazon

מוצרים שנמכרו באמזון בקיץ 2006. שני מאגרים של SNAP מכסים אותם: גרף רכישה-משותפת עם קבוצות מוצרים (Yang and Leskovec, 2012) ופרטי המוצרים שמאחוריו.

מקור	com-Amazon: הגרף (4.5 MB) והקבוצות שלו (5.5 MB). amazon-meta: פרטי מוצרים, 211 MB דחוס.
צומת	מוצר אחד. בגרף יש 334,863 מוצרים; הפרטים מכסים 548,552. סביר ששניהם משתמשים באותם מספרי מוצר, אבל זה עוד לא נבדק.
טקסט צומת	הכותרת של כל מוצר ומקומו בעץ הקטגוריות (למשל Books > Subjects > History). הביקורות נותנות תאריך, דירוג כוכבים והצבעות, אבל **אין בהן טקסט**; הגרסה הראשונה של הדוח טעתה בנקודה הזו.

קשתות ניתנות: 925,872 זוגות מוצרים שנקנים לעיתים קרובות יחד. אפשר גם לחבר מוצרים עם כותרות דומות.

תת-גרף המוצרים של קטגוריה אחת. SNAP כבר מפצל כל קטגוריה לחלקים הקשירים שלה ומשמיט חלקים של פחות מ-3 מוצרים. מוצר יכול להיות בכמה קטגוריות, ולכן נשאיר אחת.

תווית 1 אם בקטגוריה יש ספרים, אחרת 0. ספרים הם 72% מהמוצרים (393,561), אחריהם מוזיקה (103,144), סרטי וידאו (26,132) ו-DVD (19,828). דירוג ממוצע גבוה לעומת נמוך הוא תווית חלופית.

בעיות תווית הספרים לא מאוזנת לכיוון השני (רובם חיוביים), והכותרת ונתיב הקטגוריה עלולים להסגיר אותה.

Gene Ontology ו-STRING

חלבונים אנושיים. STRING נותן אילו חלבונים עובדים יחד; Gene Ontology (GO) נותן מה כל חלבון עושה, כמונחים שמסודרים בעץ. המאגר PPI-BP של SubGNN בנוי באותה דרך: 21,521 חלבונים, 1,591 תתי-גרפים של כ-10 חלבונים כל אחד, ו-6 מחלקות.

מקור STRING v12 לאדם: קשרים (79 MB), מידע על החלבונים (2 MB), שמות במאגרים אחרים (19 MB), ושתי קבוצות מוכנות של וקטורי חלבונים (19 MB ו-36 MB). GO: קובץ האנוטציות האנושי (12 MB) ועץ המונחים (32 MB). בערך 200 MB בסך הכול.

צומת חלבון אחד, בערך 19,000 ב-STRING (מהזיכרון).

טקסט צומת תיאור קצר של כל חלבון בקובץ המידע של STRING. STRING נותן גם וקטורים שנוצרו מרצף החלבון ומהרשת.

קשתות ניתנות: זוגות חלבונים עם ציון ביטחון מ-0 עד 1000. נשאיר זוגות מעל סף, למשל 700 (ביטחון גבוה).

התאמה STRING משתמש במזהים משלו ו-GO משתמש במזהי UniProt. קובץ השמות של STRING ממפה בין השניים.

תת-גרף החלבונים של מונח GO אחד. לחלבון יש מונחים רבים, ולכן נשאיר אחד, או נאפשר חפיפה.

תווית 1 אם המונח נמצא תחת ענף שנבחר בעץ של GO, אחרת 0.

בעיות תיאורי החלבונים אומרים לא פעם את התפקיד, שקרוב לתווית. חלק ממונחי GO עצמם הוסקו מאותו סוג של ראיות כמו קשתות STRING.